Predicción del bajo peso al nacer en Irán

Modelo predictivo basado en Machine Learning y registros del IMaN Net

Problemática

El bajo peso compromete la supervivencia neonatal y aumenta drásticamente los riesgos de salud a largo plazo.

Múltiples factores demográficos maternos y patologías clínicas preexistentes determinan directamente esta condición de riesgo.

Identificar tempranamente a las pacientes vulnerables salva vidas y optimiza la asignación de recursos médicos perinatales.

Dataset seleccionado

Red Materna y Neonatal Iraní (IMaN Net) validada a nivel nacional.

Registros hospitalarios exhaustivos que capturan resultados de partos y antecedentes clínicos desde enero 2020 hasta enero 2022.

Filtro estricto incluyendo solo embarazos únicos que superaron las 24 semanas de gestación sin anomalías fetales.

Paper de referencia

Machine learning-based approach for predicting low birth weight

A. Ranjbar, F. Montazeri, M. Vahidi Farashah, V. Mehrnoush, et al. (2023) · BMC Pregnancy and Childbirth

Objetivo

Evaluar el rendimiento comparativo de ocho algoritmos de Machine Learning para predecir el bajo peso al nacer.

Desarrollar un modelo de diagnóstico preventivo validado mediante métricas de área bajo la curva (AUROC), exactitud y precisión.

Dataset del estudio

Cohorte retrospectiva procesada mediante validación cruzada k-fold para garantizar integridad estadística.

Selección robusta de características predictivas basada en historiales clínicos y validación previa de expertos médicos.

1 280

0,86

70/30

0,79

Metodología, resultados y conclusiones

Variables consideradas

Historia clínica materna

Hipertensión crónica · Preeclampsia · Disfunción tiroidea · Diabetes · Hepatitis · COVID-19

Factores sociodemográficos

Edad materna · Nivel educativo · Ocupación laboral · Residencia · Consumo de sustancias

Indicadores perinatales

Edad gestacional · Atención prenatal · Anemia materna · Historial de bajo peso previo

Proceso

1. Extracción de registros nacionales del sistema IMaN Net.
2. Selección de factores predictores mediante revisión de cohortes.
3. Entrenamiento de 8 modelos con validación k-fold (70/30).
4. Evaluación comparativa mediante AUROC, Exactitud y F1.

Resultados Top 3 Modelos

Modelo Analítico	AUROC	Accuracy	F1 Score
Deep Learning	**0,86**	**0,78**	**0,76**
XGBoost Classification	0,79	0,79	0,77
Random Forest	0,79	0,78	0,77

Métricas calculadas con Python Scikit-learn. Deep Learning maximiza AUROC, pero XGBoost equilibra mejor precisión y exhaustividad.

Conclusiones

- El modelo XGBoost demostró ser el clasificador de rendimiento global más sólido (Exactitud 0,79).
- La red neuronal profunda (Deep Learning) alcanzó la mayor sensibilidad teórica (AUROC 0,86).
- La edad gestacional y el historial previo de bajo peso emergieron como los predictores críticos superiores.
- El uso preventivo de Machine Learning facilita intervenciones clínicas precisas a nivel hospitalario.