Paper de referencia

Predictive modeling with machine learning for low birth weight in the state of São Paulo: a retrospective population-based study

Allbert Velleniche de Aquino Almeida, Adriana de Oliveira Ribeiro dos Santos, Luiz Fernando Costa Nascimiento (2026)

Objetivo

Desarrollar y validar modelos de aprendizaje automático capaces de predecir la ocurrencia de bajo peso al nacer a partir de datos de nacidos vivos.

La finalidad es orientar políticas públicas de prevención y una asignación más eficiente de los recursos de salud materno-infantil.

Dataset del estudio

SINASC — Sistema de Información sobre Nacidos Vivos del Ministerio de Salud de Brasil, accedido a través de DATASUS.

Comprende todos los nacimientos vivos registrados en el estado de São Paulo, con información de la madre, el embarazo, el parto y el recién nacido.

2 677 170

registros de nacidos vivos disponibles en la base

2019–2023

cinco años completos en el estado de São Paulo

645

municipios cubiertos, 45,9 millones de habitantes

9,46 %

prevalencia de bajo peso en los registros válidos

Metodología, resultados y conclusiones

Variables consideradas

Historia médica materna

Edad al parto · Número de muertes de hijos previos · Paridad (orden de nacimiento) · Tipo de embarazo (único, gemelar, trillizo o más)

Factores socioeconómicos

Nivel educativo (6 categorías SINASC) · Estado civil (con pareja / sin pareja) · Raza o color de la madre

Indicadores prenatales

Edad gestacional · Número de consultas prenatales · Mes de inicio del control · Anomalías congénitas · Sexo del recién nacido

Proceso

1. Curación de datos: 2 677 170 ⟶ 2 548 570 registros válidos
2. Selección de variables por literatura, sin algoritmos automáticos
3. Partición 80/20 entrenamiento y test independiente
4. Entrenamiento con class_weight = balanced (Regresión Logística y Random Forest)

Resultados

Modelo	Accuracy	Recall	F1	AUC
Random Forest	0,919	0,417	0,492	0,81
Random Forest balanceado	0,890	0,554	0,488	0,78
Regresión Logística	0,925	0,399	0,502	0,85
Regresión Logística balanceada	**0,901**	**0,688**	**0,567**	**0,85**

El modelo balanceado sacrifica precisión y accuracy, pero eleva la sensibilidad de 0,399 a 0,688: detecta casi siete de cada diez casos reales.

Conclusiones

- La regresión logística balanceada logró el mejor desempeño global, superando al random forest.
- Los algoritmos simples e interpretables rinden igual o mejor en datos epidemiológicos poblacionales.
- El balanceo de clases es indispensable cuando el desenlace es poco frecuente.
- Mayor riesgo: edad materna extrema, baja escolaridad, sin pareja, embarazo múltiple y muertes de hijos previos.