

Resumen de paper: Predictive modeling with machine learning for low birth weight in the state of São Paulo: a retrospective population-based study

Allbert Velleniche de Aquino Almeida, Adriana de Oliveira Ribeiro dos SantosII, Luiz Fernando Costa Nascimento --- Sao Paulo Medical Journal, 2026

DOI: <https://doi.org/10.1590/1516-3180.2025.3373.04052026>

1. Problemática y objetivo

La problemática del bajo peso al nacer, definido por la Organización Mundial de la Salud como un peso inferior a 2500 gramos, es un indicador clave de morbilidad y mortalidad neonatal, la cual está asociado a complicaciones tanto a corto como a largo plazo en el desarrollo infantil. Se menciona que afecta al 15% de nacidos vivos alrededor del mundo como al 10% en Brasil. Entre sus factores asociados figuran las condiciones socioeconómicas desfavorables, la edad materna extrema, el bajo nivel educativo, la historia obstétrica, la prematuridad, los embarazos múltiples y el control prenatal inadecuado.

El objetivo de este estudio fue desarrollar y validar modelos de machine learning usando random forest y regresión logística para detectar esta problemática.

2. Dataset

El dataset utilizado fue el del Sistema de Información sobre Nacidos Vivos (SINASC) perteneciente al Ministerio de Salud de Brasil. Este documento tiene 2 677 170 registros que corresponde a la totalidad de nacidos vivos en el estado de Sao Paulo entre los años 2019 y 2023.

3. Metodología

El target se construyó de forma binaria a partir del peso al nacer donde se asignó el valor 1 a los nacimientos con peso inferior a 2500 gramos y el valor 0 a los de peso normal. La selección de variables predictoras no empleó algoritmos automáticos, sino que se basó en la literatura previa y en el conocimiento del dominio sobre factores de riesgo establecidos. Además, se descartaron las variables redundantes o fuertemente colineales, como las múltiples representaciones de la educación materna. Las variables finalmente consideradas se agrupan en tres bloques.

Bloque	Variables incluidas
--------	---------------------

Historia médica materna	Edad al parto; número de muertes de hijos previos; paridad (orden de nacimiento); tipo de embarazo (único, gemelar, trillizo o más).
Factores socioeconómicos	Nivel educativo (seis categorías del SINASC); estado civil (con pareja / sin pareja); raza o color autodeclarado de la madre.
Indicadores prenatales y del recién nacido	Categoría de edad gestacional (pretérmino, a término, postérmino); número de consultas prenatales; mes de inicio del control prenatal; anomalías congénitas detectadas; sexo del recién nacido.

Tabla 1: Variables predictoras consideradas en el estudio, agrupadas por bloque temático.

El procesamiento se realizó en Python sobre Google Colab, empleando NumPy, Pandas y scikit-learn. El flujo de trabajo comprendió cuatro etapas:

- Curación de datos: se excluyeron todos los registros con valores faltantes, entradas inconsistentes o categorías como «ignorado» y «no informado» en variables clave, reteniéndose 2 548 570 registros válidos de los 2 677 170 iniciales.
- Selección de variables: por relevancia epidemiológica y disponibilidad en el SINASC, descartando las redundantes o colineales.
- Partición del conjunto: 80 % para entrenamiento y 20 % para prueba independiente, mediante asignación aleatoria.
- Entrenamiento: una regresión logística y un random forest, cada uno en dos versiones, sin balanceo y con el parámetro `class_weight` ajustado a «balanced», que pondera las clases según su frecuencia inversa.

4. Resultados

De los 2 548 570 registros analizados, el 90,54 % correspondió a recién nacidos con peso normal y el 9,46 % a casos de bajo peso, lo que evidencia un desbalance marcado entre clases.

Modelo	Exactitud	Recall	F1	AUC-ROC
Random Forest	0,919	0,417	0,492	0,81
Random Forest balanceado	0,890	0,554	0,488	0,78
Regresión Logística	0,925	0,399	0,502	0,85
Regresión Logística balanceada	0,901	0,688	0,567	0,85

Tabla 2: Métricas de evaluación de los modelos sobre el conjunto de prueba, antes y después del balanceo de clases.

Se puede notar que la regresión logística balanceada fue la que tiene mejores resultados. Asimismo, resalta que el tratamiento de desbalance de clases es indispensable.