Paper de referencia

Infant birth weight estimation and low birth weight classification in United Arab Emirates using machine learning algorithms

Wasif Khan, Nazar Zaki, Mohammad M. Masud, Amir Ahmad, Luqman Ali, Nasloon Ali, Luai A. Ahmed (2022) · Scientific Reports

Objetivo

Evaluar 30 algoritmos de aprendizaje automático para estimar el peso al nacer (regresión) y clasificar el bajo peso (≤ 2500 g) a partir de características maternas.

Ofrecer una línea base para elegir modelos y variables, ya que cada estudio previo usaba un conjunto distinto de predictores maternos.

Dataset del estudio

Cohorte de nacimientos de Emiratos Árabes Unidos (Mother and Child Health Study), con historias clínicas de tres hospitales.

Reúne las variables usadas por seis estudios previos de bajo peso: datos sociodemográficos, antecedentes obstétricos, mediciones prenatales y del parto.

821
mujeres emiratíes
de tres hospitales

88
variables maternas
incluido el peso al nacer

30
algoritmos de ML
comparados en Weka

10,8 %
prevalencia de bajo peso
(89 de 821 nacimientos)

Metodología, resultados y conclusiones

Variables consideradas

Historia médica materna

Diabetes · Hipertensión · Paridad · Resultados de embarazos previos · Grupo sanguíneo · Tabaquismo

Factores sociodemográficos

Edad materna · Estado civil · Ocupación · Educación de la madre · Lugar de residencia

Indicadores prenatales

Edad gestacional · IMC · Talla y peso maternos · Presión arterial · Hemoglobina · Controles prenatales · Sexo del recién nacido

Proceso

1. Integración de 6 subsets de estudios previos: 88 variables maternas
2. Criterio MFE: fuera las variables con > 40 % de faltantes (88 → 30)
3. Selección de variables por votación de varios métodos automáticos
4. SMOTE solo en entrenamiento (50 %, 100 %, 300 % y total) 30 modelos, validación 5-fold

Resultados

Modelo	Accuracy	Recall	F1	LBW detectados
Bagging (REPTree) + SMOTE total	0,781	0,781	0,81	11 de 18
Bagging (Naive Bayes)	0,895	0,894	0,89	7 de 18
Regresión Logística	0,888	0,888	0,86	4 de 18
Regresión Logística + SMOTE 100 %	**0,902**	**0,902**	**0,89**	**6 de 18**

Las métricas están ponderadas por clase: aunque la accuracy llega a 0,902, el mejor modelo solo detecta 6 de los 18 casos de bajo peso (33 %).

Conclusiones

- La regresión logística con SMOTE al 100 % logró el mejor desempeño global (accuracy 0,902, F1 0,89).
- Para estimar el peso, Random Forest con selección de variables obtuvo el menor error (MAE 294,53 g).
- La selección de variables redujo los predictores a la mitad sin degradar el desempeño.
- Mayor riesgo: diabetes, hipertensión y edad gestacional.